



Máster
Analítica de Negocio/ Business Analytics

Trabajo Fin de Máster

*Optimización de modelos de tasación financiera en la NBA mediante PCA y
Clustering: Decodificando el valor del rendimiento en el baloncesto sin
posiciones*

Elaborado por :
Javier Cerdà Llopis

Tutor:
Alfonso Herrero

0.Resumen

La NBA actual opera como un ecosistema financiero de alta complejidad donde la gestión del *Salary Cap* determina la viabilidad competitiva de las franquicias. Sin embargo, el mercado presenta ineficiencias críticas debido a la firma de contratos basados en percepciones subjetivas o etiquetas posicionales obsoletas. Este Trabajo de Fin de Máster presenta un Producto Mínimo Viable (MVP) el cual consiste en un motor de tasación financiera, diseñado para auditar y predecir el valor de mercado real de los jugadores.

El valor diferencial del proyecto reside en su arquitectura técnica: utiliza **Análisis de Componentes Principales (PCA)** y **Clustering (K-Means)** para segmentar a los jugadores según su impacto funcional en la era del *Positionless Basketball*, eliminando los sesgos de las posiciones tradicionales. Posteriormente, un algoritmo de **Random Forest** entrena sobre una base de datos histórica de 25 años (2000-2025), utilizando una técnica de deflactación que convierte el salario en un porcentaje del límite salarial para neutralizar la inflación económica. Los resultados demuestran una alta robustez con un **R² de 0.73**, identificando ineficiencias de mercado de hasta un 30% en perfiles de rol específicos.

Más que un modelo estadístico, este MVP se posiciona como una herramienta escalable de **Business Intelligence**, diseñado para aportar ventaja competitiva a cuatro actores clave de la industria deportiva:

- **Departamentos de Front Office (Franquicias NBA):** Actúa como una herramienta de inteligencia financiera para optimizar el límite salarial, permitiendo a los *General Managers* cazar "gangas" (jugadores infravalorados económicamente) y auditar su propia plantilla para esquivar o traspasar "contratos tóxicos".
- **Agencias de Representación de Jugadores:** Proporciona un respaldo empírico e imparcial en las mesas de negociación, dotando a los agentes de datos irrefutables para maximizar y justificar la compensación económica de sus clientes durante la Agencia Libre.
- **Casas de Apuestas y Daily Fantasy Sports:** Ofrece un algoritmo de *pricing* dinámico capaz de integrarse vía API para ajustar el valor virtual de los jugadores (ej. DraftKings) o crear nuevos mercados de apuestas (*prop bets*) sobre los futuros contratos de las estrellas.

- **Medios de Comunicación y Analítica Deportiva:** Genera narrativas de alto *engagement* basadas en datos objetivos, transformando el debate subjetivo sobre quién cobra demasiado en una auditoría financiera de interés público.

Finalmente, discutir la escalabilidad del proyecto por su capacidad de crecer tanto verticalmente y horizontalmente.

Palabras clave: NBA, Machine Learning, Salary Cap, Random Forest, Clustering, Sports Analytics, Predictive Modeling.

ABSTRACT

The modern NBA is a multi-billion dollar financial ecosystem where Salary Cap management dictates on-court success. However, the market exhibits critical inefficiencies due to contracts signed based on subjective perceptions or obsolete positional labels. This Master's Thesis presents a **Minimum Viable Product (MVP)**, it consists of a financial appraisal engine designed to audit and predict the true market value of players.

The project's core innovation lies in its technical architecture: it employs **Principal Component Analysis (PCA)** and **Unsupervised Learning (K-Means)** to segment players based on their functional impact in the "Positionless Basketball" era, removing the biases of traditional roles. Subsequently, a **Random Forest** algorithm trains on a 25-year historical dataset (2000-2025), utilizing a deflation technique that converts salaries into a percentage of the Salary Cap to neutralize economic inflation. Results demonstrate high robustness with an **R² of 0.73**, identifying market inefficiencies of up to 30% in specific role profiles.

Beyond a statistical model, this MVP is positioned as a scalable **Business Intelligence** tool with direct application designed to provide a competitive advantage to four key stakeholders in the sports industry:

1. **NBA Front Offices:** Acting as a financial intelligence tool to optimize salary cap management, enabling General Managers to identify "undervalued assets" and audit rosters to avoid or offload "toxic contracts."
2. **Sports Agencies:** Providing empirical and impartial support during negotiations, equipping agents with data-driven evidence to maximize and justify client compensation during Free Agency.
3. **Betting Houses and Daily Fantasy Sports:** Offering a dynamic pricing algorithm capable of API integration to adjust virtual player values (e.g., DraftKings) or create new prop bet markets regarding future player contracts.
4. **Media and Sports Analytics:** Generating high-engagement narratives based on objective data, transforming subjective debates into data-backed financial audits of public interest.

Finally, the project's scalability is discussed, emphasizing its potential for both vertical and horizontal growth within the global sports market.

Keywords: NBA, Machine Learning, Salary Cap, Random Forest, Clustering, Sports Analytics, Predictive Modeling.

ÍNDICE

0. Resumen.....	2
1. Introducción.....	9
1.1 Estructura del mercado.....	10
1.2 Mercado laboral en los deportes.....	11
1.3. La Evolución Táctica hacia el Positionless Basketball y su Impacto en el Mercado..	12
1.4 El Paradigma del Big Data en la NBA: Del Dato al Valor de Mercado.....	13
2. Estudio estadístico.....	14
2.1 Origen y Naturaleza de los Datos.....	15
2.2 Filtrado de Ruido Estadístico.....	16
2.2.1 El Umbral de Minutos Jugados.....	16
2.2.2 Selección Variables.....	17
2.3 Correlación entre Salario y Rendimiento.....	20
3. Clustering.....	22
3.1 Preprocesamiento: Estandarización de Variables.....	22
3.2 Aprendizaje No Supervisado: Modelo K-Means Base (Clustering).....	23
3.2.1. Selección del Hiperparámetro k: El Método del Codo.....	23
3.3 Distribución y características de los clusters.....	25
3.4 Aprendizaje Supervisado: Modelo Predictivo Base (Regresión Lineal).....	27
3.4.1 Auditoría de Resultados del Modelo Base.....	27
3.5. Modelo Predictivo Random Forest y Mitigación del Sobreajuste.....	29
3.5.1 Metodología de Entrenamiento: El enfoque y la Validación Cruzada.....	29
4. Agrupamiento: Reducción de Dimensionalidad (PCA).....	31
4.1 Fundamentos Matemáticos y Finalidad.....	31
4.2 Justificación en el Contexto del Estudio (El Problema de la Colinealidad).....	32
4.3 Implementación y Mejora del Silhouette Score.....	32
5. Estimación Salarial Avanzada: Random Forest y Validación Hold-Out (80/20).....	34
5.1 Comparativa Metodológica: Validación Estática vs. Validación Temporal.....	35
6. El Modelo Definitivo: Deflactación Histórica y Predicción por Porcentaje del Límite Salarial.....	37
6.1 Ingeniería de Variables: Resolviendo la Inflación del Mercado.....	37
6.2. Resultados del Modelo Histórico (Validación Temporal 25 Años).....	38
6.3 Análisis de Resultados por Rol Táctico (Cluster).....	39
6.4 El Clúster 2: Auditoría de las "Gangas" y Arbitraje Financiero en el Mercado NBA..	41
7. Discusión.....	43
7.1. Interpretación de los Resultados en Relación con los Objetivos Iniciales.....	43
7.2 Contraste de Hallazgos con la Literatura y Estudios Previos.....	44
8. Conclusiones.....	47
9. Limitaciones del estudio.....	48
10. Expansión del negocio.....	49
10.1. Estrategia de Escalabilidad Vertical: Evolución del MVP a una Solución Enterprise..	50

10.2 Estrategia de Escalabilidad Horizontal: Transferencia Tecnológica Multiliga y Multideporte.....	52
11.BIBLIOGRAFÍA.....	54
12.ANEXOS.....	55

ÍNDICE DE FIGURAS

Figura 1: Heatmap variables estadísticas	18
Figura 2 : Scatter Plot Puntos y Salario	21
Figura 3: Elbow Method	24
Tabla 1: Agrupación de clusters	25
Figura 4: Perfil estadístico de los clusters ordenados por relevancia	26
Figura 5 : Agrupación por PCA	33
Figura 6 : Gráfico dispersión Clusters	34
Tabla 2 : Comparación validación de modelos	36
Figura 7 : Comparativa Salario Real vs Predicho por Clústers	39
Figura A1 :Page 1: Roster Optimizer - Team Financial Audit	56
Figura A2 : Page 2: Player Valuation Profile - Individual Meritocratic Audit	57
Figura A3: Page 3: Market Efficiency – Matriz de Scouting Avanzado y Auditoría de Sesgos	58
Figura A4: Page 4: Historical Player Comparison - Multidimensional Roster Scouting	59

1.Introducción

La Asociación Nacional de Baloncesto (NBA) es una de las ligas más populares y rentables del mundo. Si bien su esencia es el baloncesto, se ha convertido en una poderosa industria global que genera miles de millones de dólares cada año. Su éxito no solo se basa en la calidad del juego, sino también en su modelo de negocio, que incluye múltiples fuentes de ingresos y estrategias de expansión. Uno de los principales motores económicos de la NBA son los contratos televisivos. Cadenas como ESPN y TNT pagan miles de millones de dólares por los derechos de transmisión; por ejemplo, en 2016, la liga firmó un acuerdo de 24 mil millones de dólares por nueve años. Otra importante fuente de ingresos proviene de los patrocinios y la publicidad. Marcas como Nike, Gatorade y Microsoft invierten millones en acuerdos con la liga y sus jugadores. Además, la experiencia en el estadio también constituye un negocio en sí mismo. La venta de entradas, abonos de temporada y experiencias VIP genera millones para las franquicias, mientras que la venta de camisetas, zapatillas y otros productos oficiales fortalece el sector del merchandising. Asimismo, la NBA ha logrado internacionalizarse como ninguna otra liga. Su presencia en China, Europa y Latinoamérica ha permitido que los ingresos crezcan más allá de Estados Unidos, expandiendo la liga a nuevos mercados y ampliando su base de aficionados a nivel mundial.

La popularidad de la NBA ha crecido significativamente, impulsada por atletas superestrellas y la llegada de jugadores internacionales. A medida que la popularidad de la liga ha aumentado, también lo han hecho los ingresos generados por las franquicias de la NBA cada temporada. Esto ha propiciado que los jugadores puedan firmar contratos muy lucrativos; por ejemplo, los contratos de las superestrellas superan los 200 millones de dólares. El pívot serbio Nikola Jokic firmó en 2022 un contrato de 276 millones de dólares por 5 años con los Denver Nuggets, lo que supone un salario anual promedio de 55,2 millones de dólares. En 2025 el base Shai Gilgeous-Alexander llegó a un acuerdo con los Oklahoma City Thunder para una extensión de su contrato por de 4 años y \$285 millones de dólares, lo que significa un total de 71\$ millones por temporada.

En la década de 1990, un equipo podría valer alrededor de 100 millones de dólares, pero hoy en día, las franquicias más valiosas, como Los Angeles Lakers o los Golden State Warriors, están valoradas en más de 5 mil millones de dólares. El gran ejemplo para demostrar el poder económico de la liga es la reciente venta de los Boston Celtics. A finales de 2025, Bill

Chisholm, socio gerente de Symphony Technology Group, compró los Boston Celtics por \$6,100 millones de dólares a la familia Grousbeck, anterior propietaria que compró la franquicia en 2002 por \$360 millones.

Esto demuestra que el valor económico de la NBA se ha disparado y confirma que es un negocio altamente rentable, afianzando su posición como una de las ligas más rentables del mundo.

1.1 Estructura del mercado

La estructura salarial de la NBA está moldeada por un complejo sistema institucional diseñado para mantener el equilibrio competitivo y controlar el gasto de los equipos. Esta estructura se rige por un **límite salarial blando** (*soft salary cap*), que establece un tope a las nóminas de los equipos pero permite excepciones, como la *Excepción Bird* y diversas extensiones de nivel medio y para veteranos que otorgan flexibilidad a los equipos bajo el **Convenio Colectivo** (CBA). Además, los límites de salario máximo restringen las ganancias de los jugadores individuales según su nivel de experiencia, y el sistema de **impuesto de lujo** penaliza a los equipos que exceden el límite por un margen sustancial.

Sin embargo, varios economistas han argumentado que este marco institucional introduce distorsiones de mercado que limitan la efectividad de la compensación basada en el desempeño. [7] **Scully y Gerald (1995)** en “*The Market Structure of Sports.*” sostiene que la naturaleza regulada de los mercados deportivos profesionales —caracterizada por la movilidad limitada de los jugadores, el uso de *drafts* y los topes salariales— impide el libre funcionamiento de la oferta y la demanda laboral, lo que resulta en una desconexión entre la productividad marginal de un jugador y su salario real. Esta crítica coincide con el análisis más amplio de [8] **Rosen y Sanderson (2001)**, quienes argumentan que los mercados laborales en el deporte profesional son inherentemente diferentes de los mercados tradicionales, debido a su dependencia de convenios colectivos, estructuras de liga monopolísticas y mecanismos de reparto de ingresos. Estas restricciones limitan la competencia salarial y reducen la capacidad de los sistemas de pago basados en el desempeño para funcionar eficientemente.

En conjunto, estos estudios sugieren que, si bien el desempeño es un determinante importante de la compensación, el diseño institucional de la NBA a menudo restringe la capacidad del

mercado para recompensar a los jugadores en proporción a su contribución real, creando ineficiencias y potenciales inequidades en la distribución salarial.

1. 2 Mercado laboral en los deportes

La primera pregunta que debemos hacernos es si a los jugadores se les paga por su desempeño. Diversos estudios han demostrado que la compensación basada en el rendimiento es una práctica común en el diseño de los sistemas salariales. Por ejemplo, el trabajo de **[3] Gerhart y Milkovich (1992)** en “*Employee compensation: Research and practice*” muestra que uno de los principales determinantes de la compensación en las organizaciones es el desempeño individual. Los autores proponen que los sistemas de incentivos, cuando están bien diseñados, permiten alinear los objetivos de la empresa con los comportamientos deseados de los empleados, reforzando la idea de que a los trabajadores se les paga en función de su rendimiento.

Del mismo modo, **[8] Bryson y Forth (2007)**, en su análisis del sector público británico, encuentran que la implementación de esquemas de pago por desempeño está asociada con diferencias en la satisfacción laboral, confirmando la existencia de mecanismos de compensación vinculados al rendimiento incluso en entornos no competitivos. Ambos estudios coinciden en que el desempeño del empleado es una variable clave para determinar su nivel de compensación, independientemente del sector o nivel jerárquico.

Pasando al sector deportivo, tanto **[6] Scully (1974)**, en “*Pay and Performance in Major League Baseball*” en el contexto de las Grandes Ligas de Béisbol (MLB), como **[5] DeSchryvere y Howard (2007)**, en “*An analysis of the salary structure in the National Basketball Association*” donde analiza la estructura salarial en la NBA, comparten un tema central: la relación entre el desempeño del jugador y su salario. Cada estudio utiliza métodos econométricos para examinar cómo el rendimiento individual se traduce en compensación económica. Scully introduce la idea del valor marginal de un jugador, demostrando que muchos atletas no recibían un pago acorde a su contribución real. De manera similar, DeSchriver y Howard encuentran que en la NBA, ciertas métricas ofensivas, particularmente los puntos por partido, tienen una influencia desmedida en la determinación del salario, mientras que otros aspectos importantes del desempeño son infravalorados. En conjunto, estos estudios revelan que, aunque existe una conexión entre desempeño y salario, esta

relación no siempre es eficiente ni justa, lo que resalta la existencia de distorsiones salariales dentro del deporte profesional.

1.3. La Evolución Táctica hacia el *Positionless Basketball* y su Impacto en el Mercado

Para comprender la necesidad de un enfoque analítico avanzado en la tasación salarial, es imperativo analizar la profunda transformación táctica que ha experimentado la NBA en la última década. El modelo tradicional de baloncesto estructuraba los equipos en torno a cinco posiciones rígidas y bien definidas: Base (*Point Guard*), Escolta (*Shooting Guard*), Alero (*Small Forward*), Ala-Pivot (*Power Forward*) y Pivot (*Center*). Cada uno de estos roles tenía asignada una parcela geométrica y funcional exclusiva en la pista. Sin embargo, la revolución del triple, la búsqueda de la eficiencia espacial (*spacing*) y la exigencia de versatilidad defensiva han dado paso a la era del *Positionless Basketball* o baloncesto sin posiciones.

Esta transición no es solo una tendencia en la pizarra de los entrenadores; es una realidad empíricamente demostrada por la ciencia de datos aplicada al deporte. El estudio pionero de [9] Alagappan (2012) “*From 5 to 13*”, marcó un hito académico al aplicar algoritmos de agrupamiento no supervisado sobre estadísticas de rendimiento, revelando que la estructura real de la liga no se dividía en cinco categorías, sino en al menos trece roles funcionales latentes (como *creadores de perímetro*, *finalizadores de pintura* o *especialistas defensivos*). En este nuevo paradigma, los atributos físicos tradicionales ya no dictan la función de un atleta. Jugadores de gran envergadura actúan como directores de juego principales, mientras que los escoltas asumen funciones de rebote y protección interior, haciendo que las etiquetas clásicas del *box score* resulten obsoletas y sesgadas.

Desde la perspectiva de *Business Analytics*, la persistencia de las franquicias en utilizar las posiciones tradicionales para negociar contratos o estructurar plantillas introduce una grave asimetría de información y una ineficiencia en la asignación de capital. Evaluar el salario de un jugador comparándolo exclusivamente con los promedios de su "posición teórica" penaliza a los perfiles híbridos y sobrevalora a jugadores unidimensionales. Por tanto, este TFM justifica el uso de técnicas de *Clustering* (K-Means) precisamente como la respuesta tecnológica necesaria a esta evolución táctica. Al permitir que los algoritmos identifiquen los roles reales basados en el impacto estadístico puro y no en etiquetas administrativas, el motor de tasación logra limpiar el ruido del mercado, garantizando que la valoración económica

final se sustente sobre la verdadera función operativa del jugador en la era del baloncesto moderno.

1.4 El Paradigma del Big Data en la NBA: Del Dato al Valor de Mercado

En la última década, la NBA ha transitado de una liga basada en la intuición de los *scouts* a un ecosistema gobernado por el **Big Data**. La implementación de sistemas de seguimiento óptico (como Second Spectrum) ha generado una explosión de métricas avanzadas que capturan cada micro-evento en la pista. Sin embargo, esta abundancia de información ha dado lugar a la "paradoja del ruido": las franquicias poseen más datos que nunca, pero siguen incurriendo en errores multimillonarios al firmar contratos que no guardan una relación lineal con la productividad real.

El problema de negocio central no es la falta de datos, sino la **ineficiencia en su procesamiento**. Los modelos de tasación tradicionales suelen caer en dos errores críticos que este TFM se propone resolver:

1.1 La Ineficiencia de las Posiciones Tradicionales

Como hemos dicho, el mercado laboral de la NBA todavía categoriza a los jugadores en cinco posiciones clásicas (Base, Escolta, Alero, Ala-Pívot y Pívot). No obstante, en la era del *Positionless Basketball*, estas etiquetas son insuficientes y engañosas. Un "Base" como Luka Doncic comparte más rasgos estadísticos con un "Pívot" pasador que con un base organizador tradicional.

Intentar predecir un salario basándose en etiquetas obsoletas introduce un sesgo estructural en cualquier modelo. Por ello, este estudio implementa un aprendizaje no supervisado mediante **K-Means**. El objetivo es permitir que los datos "hablen por sí mismos" para agrupar a los jugadores en **clústeres de rendimiento funcional** (ej. *creadores de élite, finalizadores de pintura, especialistas 3&D*). Solo mediante esta segmentación algorítmica previa podemos establecer una base de comparación justa: no comparamos a un jugador con su "posición", sino con su "rol táctico real" en la pista.

2. La Maldición de la Dimensionalidad y la Colinealidad

El rendimiento de un jugador se mide hoy a través de decenas de variables (puntos, rebotes, asistencias, win shares, box plus-minus, porcentajes de tiro corregidos, etc.). Introducir todas estas variables directamente en un modelo de regresión generaría multicolinealidad: muchas métricas están intrínsecamente correlacionadas (ej. los minutos jugados con el volumen de puntos).

Para garantizar la robustez del modelo y eliminar el ruido redundante, este proyecto aplica el **Análisis de Componentes Principales (PCA)**. Esta técnica de reducción de dimensionalidad nos permite destilar la esencia del rendimiento en un conjunto de "Súper-Variables" ortogonales (independientes entre sí). El PCA no solo simplifica el modelo, sino que purifica la señal estadística, permitiendo que el algoritmo de **Random Forest** posterior identifique los verdaderos *drivers* del valor económico sin verse confundido por la redundancia de los datos.

2. Estudio estadístico

Antes de desarrollar un modelo salarial basado en el desempeño, vale la pena reconocer que la compensación es un concepto polifacético. [2] **Kasprzyk y Beata (2018)** en "*Application of econometric models to measure the satisfaction with wages and salaries*" resalta esta complejidad aplicando modelos econométricos para analizar la satisfacción salarial desde un punto de vista subjetivo. Su estudio revela que las percepciones de justicia y equidad de los empleados desempeñan un papel significativo en la evaluación de los salarios, sugiriendo que el ingreso por sí solo no determina la satisfacción.

Sin embargo, los deportes profesionales ofrecen un entorno único donde el rendimiento es altamente medible, lo que permite a los investigadores centrarse de manera más directa en la relación entre el rendimiento y la compensación. Partiendo de esta premisa, la siguiente sección introduce un modelo base que busca explicar los salarios de los jugadores de la NBA como una función de las métricas de desempeño en la pista.

2.1 Origen y Naturaleza de los Datos

Para la consecución de los objetivos de este Trabajo de Fin de Máster, la materia prima fundamental ha sido la recopilación y estructuración de un conjunto de datos (*dataset*) histórico de la NBA, los cuales representan estadísticas de performance por partido de cada jugador con su respectivo salario de esa temporada.

El dataset ha sido obtenido desde Kaggle, "NBA Player Stats and Salaries 2000-2025", el cual ha sido construido a partir de otros datasets con las estadísticas de los jugadores procedentes de GitHub y scrapeando los salarios en la web HoopsHype. Para las primeras estimaciones del estudio para los primeros modelos el marco temporal ha sido modificado, seleccionando las temporadas comprendidas entre los años 2020 y 2025.

La elección de esta ventana de cinco años no es casual: permite capturar la realidad económica actual de la liga tras las recientes firmas del Convenio Colectivo (CBA) y refleja el estilo de juego contemporáneo, caracterizado por el alto volumen de lanzamiento exterior y la difuminación de las posiciones tradicionales (*Positionless Basketball*).

Los datos han sido extraídos de registros estadísticos oficiales y estructurados en una base de datos tabular. Cada fila de este *dataset* representa la temporada individual de un jugador, y cada columna representa una estadística que el jugador ha obtenido dicha temporada las cuales servirán como variables para el futuro modelo.

El tamaño del dataset es de:

- 2909 jugadores (Filas)
- 31 estadísticas (columnas)

Las estadísticas recogidas en el dataset son las siguientes:

- **Player:** Nombre del jugador
- **Salary:** Salario del jugador esa temporada
- **Year :** Año de la temporada
- **Pos :** Posición en la que juega
- **Age:** Edad que tiene esa temporada
- **Team :** Equipo en el que juega
- **G:** Total de partidos jugados en la temporada regular

- **GS:** Total de partidos en los que el jugador fue titular
- **MP:** Promedio de minutos jugados por partido
- **FG:** Promedio de tiros de campo anotados por partido
- **FGA:** Promedio de intentos de tiros de campo por partido
- **FG%:** Porcentaje promedio de tiros de campo por partido
- **3P:** Promedio de triples anotados por partido
- **3PA:** Promedio de intentos de triples por partido
- **3P%:** Porcentaje promedio de acierto en triples por partido
- **2P:** Promedio de tiros de dos puntos anotados por partido
- **2PA:** Promedio de intentos de tiros de dos puntos por partido
- **2P%:** Porcentaje promedio de acierto en tiros de dos puntos por partido
- **eFG%:** Porcentaje de tiros de campo efectivo
- **FT:** Promedio de tiros libres anotados por partido
- **FTA:** Promedio de intentos de tiros libres por partido
- **FT%:** Porcentaje promedio de acierto en tiros libres por partido
- **ORB:** Promedio de rebotes ofensivos capturados por partido
- **DRB:** Promedio de rebotes defensivos capturados por partido
- **TRB:** Promedio total de rebotes capturados por partido
- **AST:** Promedio de asistencias por partido
- **STL:** Promedio de robos de balón por partido
- **BLK:** Promedio de bloqueos (tapones) por partido
- **TOV:** Promedio de pérdidas de balón por partido
- **PF:** Promedio de faltas personales cometidas por partido
- **PTS:** Promedio de puntos por partido

2.2 Filtrado de Ruido Estadístico

2.2.1 El Umbral de Minutos Jugados

Una vez consolidado el conjunto de datos inicial, se aplicó un filtro de exclusión fundamental para la viabilidad y precisión del estudio: la restricción de la muestra a aquellos jugadores que promediaron, como mínimo, **10 minutos jugados por partido (MP $\geq$ 10)**.

Esta decisión metodológica se fundamenta en dos pilares críticos para el modelado:

1. Prevención de la Varianza por Muestras Pequeñas (*Small Sample Size*): Desde un punto de vista puramente estadístico, los jugadores con una participación residual (conocidos habitualmente como fondo de banquillo o jugadores de *garbage time*) presentan métricas de eficiencia extremadamente volátiles y engañosas. Un jugador que disputa apenas dos minutos en un partido resuelto y anota su único tiro a canasta registrará un porcentaje de tiro Efectivo (eFG%) del 100%. Si estos registros extremos no se filtran, los algoritmos de *Machine Learning* futuros interpretarán erróneamente estos picos de varianza como talento de élite, corrompiendo la fase de *Clustering* y las predicciones posteriores.


2. Dinámica del Mercado Laboral de la NBA: Desde la perspectiva de negocio, el objetivo de este TFM es crear un modelo de tasación salarial basado en el rendimiento de mercado. Los atletas que no logran entrar en la rotación regular de un equipo (menos de 10 minutos por encuentro) operan bajo una realidad financiera distinta: sus compensaciones están dictadas casi exclusivamente por el Convenio Colectivo mediante salarios mínimos regulados, contratos duales (*two-way contracts*) o contratos temporales de 10 días. Su remuneración responde a un estándar administrativo, no a una negociación basada en su producción en la pista.

Por consiguiente, el establecimiento de este umbral garantiza que nuestros algoritmos (K-Means y Random Forest) se entrenen de forma exclusiva con "jugadores de rotación", es decir, aquellos cuyo impacto deportivo es lo suficientemente significativo como para influir de forma directa en las negociaciones reales del mercado libre de la NBA. Al eliminar este ruido, se maximiza la ratio señal/ruido del modelo predictivo.

2.2.2 Selección Variables.

En el análisis de estadísticas de baloncesto, la redundancia de datos es un fenómeno intrínseco: muchas métricas clásicas del *box score* están vinculadas por una causalidad directa (por ejemplo, los tiros de campo anotados y los puntos totales). Para asegurar la estabilidad técnica del modelo y facilitar la posterior interpretación de los resultados, se realizó un análisis de multicolinealidad mediante una matriz de correlación visualizada con un *Heatmap*.

Figura 1: Heatmap variables estadísticas



Fuente : Fuentes propias

Mediante la figura 1, se aplica un criterio de selección adoptado fue la **exclusión de aquellas variables que presentaran un coeficiente de correlación de Pearson superior a 0,95**. Esta decisión metodológica, aplicada de forma previa al Análisis de Componentes Principales (PCA), responde a dos necesidades estratégicas:

1. **Simplificación Lógica del Modelo:** Aunque el PCA es capaz de colapsar variables correlacionadas en nuevas dimensiones ortogonales, introducir variables con colinealidad casi perfecta (como **FGA** y **FG**) puede generar "ruido geométrico". Al realizar esta criba manual, nos aseguramos de que el PCA trabaje sobre un espacio de características donde cada variable aporta una faceta de rendimiento estadísticamente diferenciada.

2. **Interpretabilidad de los Clústeres:** Al reducir la redundancia extrema antes de la segmentación con K-Means, evitamos que ciertos rasgos (como el volumen de tiro) tengan un peso desproporcionado en la formación de los roles tácticos. Esto permite que el modelo identifique de manera más nítida perfiles híbridos o especialistas, sin verse sesgado por la repetición del mismo concepto bajo diferentes etiquetas estadísticas.

El resultado del análisis del Heatmap ha sido la selección y agrupación de las siguientes variables:

1. Variables categóricas las cuales usaremos para identificar y darle contexto al estudio, pero no serán utilizadas en los modelos posteriores para realizar cálculos.

Estas son las siguientes :

- Player (Jugador): Nombre completo del atleta.
- Year (Año): Temporada en la que se registraron las estadísticas.
- Team (Equipo): Franquicia a la que pertenecía el jugador.
- Pos(Position): Posición en la que juega

2. Variable Objetivo Económica (*Target*):

- Salary (Salario): Sueldo anual percibido por el jugador en dólares estadounidenses. Esta será la variable dependiente que nuestro modelo de *Machine Learning* aprenderá a predecir para establecer el "Salario Justo" o valor real de mercado.

3. Variables de Rendimiento Deportivo (*Features*) y Edad: Se han seleccionado 13 métricas clave del "Box Score" (variables numéricas) y eficiencia que resumen el impacto del jugador en la pista, todas ellas estandarizadas (porcentajes o promedios por partido) para evitar sesgos por volumen de partidos jugados. A las cuales se les suma también la variable de la edad, dado que la experiencia en el deporte es significativa.

Las variables son las siguientes:

- MP (Minutes Played): Minutos jugados por partido.

- G(Games): Partidos totales jugados.
- GS(Games Starter): Partidos en los que ha sido titular
- PTS (Points): Puntos anotados.
- TRB (Total Rebounds): Rebotes totales por partido (ofensivos y defensivos).
- ORB(Offensive Rebounds) Rebotes Ofensivos por partido
- PF(Player Fouls): Falta cometidas por partido
- AST (Assists): Asistencias repartidas por partido
- STL (Steals) y BLK (Blocks): Robos de balón y tapones por partido (indicadores defensivos).
- TOV (Turnovers): Pérdidas de balón por partido(indicador de ineficiencia o riesgo).
- eFG% (Effective Field Goal Percentage): Porcentaje de tiro efectivo, una métrica avanzada que otorga un 50% más de valor a los tiros de tres puntos para reflejar la realidad matemática del juego.
- FG%(Field Goal Percentage): Porcentaje de tiros de campo
- 3P% ,2P% y FT%: Porcentajes de acierto en tiros de tres puntos, tiros de dos puntos y tiros libres.
- 3P,2P,FT : Promedio de tiros de 3 puntos, 2 puntos y tiros libres anotados
- Age (Edad): Edad del jugador en dicha temporada, factor crítico para evaluar su madurez y proyección salarial.


La consolidación de estas variables nos proporciona una radiografía completa y cuantificable del valor aportado por cada atleta a su franquicia, consolidando una base de datos final con las variables más representativas del impacto en pista. Garantizando que el motor de tasación salarial opere sobre una señal estadística purificada y libre de redundancias estructurales para la fase de modelado predictivo y dejando una base de datos final con 2406 filas y 20 columnas.

2.3 Correlación entre Salario y Rendimiento

Antes de implementar cualquier arquitectura predictiva de *Machine Learning*, es un imperativo metodológico validar empíricamente la hipótesis fundamental que da origen a este estudio, ¿Existe realmente una relación matemática demostrable entre la producción estadística de un jugador en la pista y su compensación económica?

Para responder a esta interrogante y justificar la viabilidad del proyecto, nos podemos fijar primeramente en la figura 1 Heatmap anterior, la cual representa una matriz de correlación de las variables. Sí observamos el salario en la figura vemos que mantiene correlación positiva con todas las demás variables. La correlación más grande corresponde con la variable que recoge los puntos por partido (PTS), con un 0,7 lo que sugiere que la NBA sigue siendo una liga impulsada por la capacidad ofensiva pura. En la figura 2, observamos la relación directa que tienen los puntos con los salarios, esto en términos de mercado significa que la capacidad de generar puntos propios sigue siendo el activo mejor remunerado por los *General Managers*.

Figura 2 : Scatter Plot Puntos y Salario



Fuente : Fuentes propias

Métricas de generación de juego y protección de aro, como las Asistencias (AST) o los Rebotes Totales (TRB), muestran una correlación positiva más moderada. Esto sugiere que su impacto económico está fuertemente condicionado por la posición del jugador. Un volumen alto de asistencias garantiza un gran contrato en bases organizadores, pero no tiene el mismo peso en perfiles interiores. Este hallazgo empírico justifica matemáticamente la decisión metodológica de aplicar algoritmos de agrupamiento (*Clustering* mediante K-Means) para segmentar a la liga por roles antes de realizar tasaciones.

Por otro lado, se detectó una paradoja estadística en las métricas avanzadas. El Porcentaje de Tiro Efectivo (eFG%) presentó una correlación débil frente al salario. Este dato muestra que existen jugadores de rol especializados en finalizar cerca del aro que poseen porcentajes de acierto altísimos (eFG% > 60%) pero perciben salarios mínimos. En contraparte, las súper estrellas asumen tiros de alta dificultad que reducen ligeramente sus porcentajes, pero perciben contratos máximos.

Finalmente, respaldándonos en otros estudios, como [1] **Robert Lyons, Jackson, E., & Livingston, A. (2015)** “*Determinantes de los Salarios de los Jugadores de la NBA*”, demostró que los puntos y los tiros de campo por partido eran las principales estadísticas que contribuyen al salario de un jugador. Este estudio tiene como objetivo evaluar si los tiros de tres puntos son más significativos que otras estadísticas a la hora de determinar el salario de un jugador.

3. Clustering

3.1 Preprocesamiento: Estandarización de Variables

Previamente a la aplicación de cualquier algoritmo de agrupamiento, es un requisito matemático ineludible realizar un escalado de las características (*Feature Scaling*). Los algoritmos basados en distancias, como es el caso del K-Means que utiliza la distancia euclídea, son extremadamente sensibles a la magnitud de las variables.

En nuestro conjunto de datos, conviven métricas con escalas completamente dispares: los Puntos (PTS) o los Minutos (MP) pueden alcanzar valores de 30 o 40, mientras que variables de eficiencia como el Porcentaje de Tiro Efectivo (eFG%) operan estrictamente en un rango de 0 a 1. Si no se corrigiera esta asimetría, el algoritmo otorgaría un peso desproporcionado a los puntos simplemente por tener valores absolutos más altos, ignorando por completo el impacto de la eficiencia o los porcentajes.

Para neutralizar este sesgo, se aplicó la técnica de estandarización (*StandardScaler*) sobre las variables de rendimiento deportivo y la edad nombradas anteriormente. Lo cual transforma cada variable restándole su media (μ) y dividiéndola por su desviación estándar (σ). Como resultado, todas las variables estadísticas pasaron a tener una media de 0 y una varianza de 1

(puntuaciones Z), garantizando que el algoritmo evaluará el rendimiento del jugador de forma equilibrada en todas sus dimensiones.


3.2 Aprendizaje No Supervisado: Modelo K-Means Base (Clustering)

Con el espacio de características estandarizado, el primer gran objetivo analítico consiste en segmentar a los jugadores de la NBA en grupos homogéneos según su producción estadística, ignorando deliberadamente las posiciones tradicionales (Base, Escolta, Alero, Ala-Pívot y Pívot). En el baloncesto moderno, la difuminación de los roles exige una clasificación puramente matemática basada en el rendimiento real.

3.2.1. Selección del Hiperparámetro k : El Método del Codo

Para determinar el número óptimo de agrupaciones y evitar una asignación arbitraria del hiper parámetro k , se recurrió a la técnica heurística conocida como el **Método del Codo** (*Elbow Method*). Este método evalúa la compactación de los grupos calculando la Inercia —la Suma de los Cuadrados de las Distancias de cada punto al centroide de su clúster (WCSS, por sus siglas en inglés)— para un rango secuencial de valores de k (en nuestro caso, iterando de 1 a 10 clústeres).

Figura 3: Elbow Method



Fuente: Fuentes propias

Como se puede observar en la gráfica superior de la figura 3, la inercia experimenta una caída drástica y pronunciada en los primeros valores de k , a medida que el algoritmo empieza a separar los perfiles más extremos de la liga. Sin embargo, al alcanzar el valor de $k=4$, la curva comienza a aplanarse significativamente.

Este punto de inflexión matemático (el "codo" de la gráfica) nos indica que el beneficio marginal de añadir un sexto o séptimo clúster —en términos de reducción de la varianza interna— es mínimo y correría el riesgo de sobre segmentar la muestra de jugadores. Además, este valor $k=4$ obtenido empíricamente resultó tener un encaje de negocio perfecto, permitiendo perfilar los ecosistemas actuales de las plantillas NBA.

Para validar de forma empírica esta heurística y descartar escenarios de subajuste o sobreajuste, se ejecutaron pruebas experimentales fijando un hiper parámetro de $k = 5$. No obstante, el análisis geométrico y matemático de los nuevos centroides criminalizó esta solución: dos de los cinco clústeres resultantes presentaron perfiles de coordenadas en el espacio de los componentes principales prácticamente idénticos. Esto provocó un severo

solapamiento funcional y estadístico, demostrando que una quinta partición fragmentaba artificialmente la muestra sin añadir información relevante. Asimismo, el cálculo complementario del Coeficiente de Silueta (Silhouette Score) confirmó que la configuración de $k = 4$ maximiza de forma óptima la separación inter clúster y la cohesión interna. Incrementar el valor a $k = 5$ reducía drásticamente las puntuaciones de silueta globales y provocaba que múltiples observaciones quedarán clasificadas en zonas de alta ambigüedad matemática.

Una vez justificado el hiper parámetro, el algoritmo itera sobre las 20 variables estadísticas de forma simultánea para asignar a cada jugador a su perfil matemático más afín.

3.3 Distribución y características de los clusters

En la siguiente tabla 1, vemos distribución por clusters que nos ha dejado la segmentación::

Tabla 1: Agrupación de clusters

Cluster	Número de jugadores
0	346
1	923
2	732
3	405

Fuente: Fuentes propias

Las características estadísticas de cada cluster son recogidas en la Figura 4, donde podemos ver los clusters ordenados por su relevancia y han sido las siguientes:

Figura 4: Perfil estadístico de los clusters ordenados por relevancia

... Perfil Estadístico de los Clusters (Medias):									
Cluster	Age	G	MP	eFG%	3P	2P	FT	3P%	2P%
3	0.12	0.40	1.41	0.03	0.99	1.61	1.70	0.28	-0.01
2	0.10	0.46	0.48	0.04	0.52	-0.11	-0.08	0.39	-0.14
0	-0.09	0.05	-0.23	1.08	-1.05	0.34	-0.17	-1.15	1.12
1	-0.10	-0.56	-0.91	-0.45	-0.45	-0.74	-0.62	-0.00	-0.30

Cluster	AST	STL	BLK	TOV	PF	PTS	Salary
3	1.53	1.01	0.29	1.69	0.68	1.76	26269469.43
2	0.13	0.37	-0.15	0.05	0.27	0.13	10346111.47
0	-0.56	-0.37	1.22	-0.26	0.60	-0.27	8475484.45
1	-0.57	-0.59	-0.46	-0.68	-0.74	-0.77	3740544.43

Fuente: Fuentes propias

Cluster 3 (Superestrellas Ofensivas / Creadores de Juego): Estos son los jugadores más dominantes ofensivamente. Tienen una alta puntuación en MP (Minutos Jugados), AST (Asistencias) y PTS (Puntos). También muestran buenos valores en STL (Robos) y TOV (Pérdidas de Balón), lo cual es común en jugadores con alto volumen de balón. Su eFG% (Porcentaje de Tiros Efectivos) y 3P% (Porcentaje de Tiros de 3 Puntos) son positivos, indicando eficiencia, y su salario promedio es el más alto, lo que confirma su estatus de élite. La edad es ligeramente superior a la media, sugiriendo jugadores en su prime o veteranos dominantes.

Cluster 2 (Jugadores Todoterreno / Jugadores Secundarios / Rol): Este cluster representa a jugadores muy completos y valiosos. Tienen buenos promedios en casi todas las categorías, con valores positivos en G (Partidos Jugados), MP (Minutos Jugados), 3P% (Porcentaje de Tiros de 3 Puntos) y PTS (Puntos). No destacan marcadamente en una sola área pero su contribución es consistente en ofensiva y defensa (STL positivo). Su salario promedio es el segundo más alto.

Cluster 0 (Pivotes Defensivos / Especialistas en Pintura): Estos jugadores se caracterizan como protectores del aro por su impacto defensivo y reboteador. Tienen un eFG% muy alto (por encima de la media), pero un 3P% muy bajo y negativo, lo que sugiere que operan principalmente cerca del aro. Destacan notablemente en BLK (Tapones) y TRB (Rebotes), y tienen un FT% (Porcentaje de Tiros Libres) bajo y negativo, que es típico de muchos

jugadores grandes. Su salario es similar al del Cluster 0, lo que indica que el mercado valora a los especialistas defensivos.

Cluster 1 (Jugadores de Banquillo / Final rotación): Este cluster agrupa a jugadores con roles más específicos y menos minutos en cancha. Sus estadísticas promedio son consistentemente negativas en la mayoría de las categorías principales (MP, PTS, TRB, AST, STL, BLK, TOV, PF), lo que indica un menor volumen de juego y, por ende, menor impacto individual. Sin embargo, su eficiencia (eFG%, 3P%, 2P%) es decente, lo que sugiere que son eficientes en las oportunidades que tienen. Tienen el salario promedio más bajo, reflejando su rol de final de la rotación de un equipo.

3.4 Aprendizaje Supervisado: Modelo Predictivo Base (Regresión Lineal)

Una vez segmentada la liga en cuatro ecosistemas de rendimiento ($k=4$), el siguiente paso metodológico consiste en trazar la equivalencia matemática entre la producción deportiva y la compensación económica. Para establecer una línea base de predicción (*Baseline Model*), se opta por entrenar un algoritmo de Regresión Lineal Múltiple.

Con el objetivo de capturar las particularidades de cada rol, no se entrenó un único modelo para toda la liga, sino que se instancia una regresión independiente para cada uno de los cuatro clústeres. La hipótesis de partida asume que un punto o un rebote no se pagan igual en un jugador de rotación que en una súper estrella.

3.4.1 Auditoría de Resultados del Modelo Base

Para empezar a evaluar la calidad de esta primera segmentación, se recurrió al Coeficiente de Silueta (*Silhouette Score*), una métrica que evalúa cuán similar es un objeto a su propio clúster en comparación con otros clústeres, oscilando entre -1 y 1.

El modelo K-Means base arrojó un *Silhouette Score* de 0.170. Aunque este valor positivo confirma que el algoritmo logró identificar patrones subyacentes reales, el margen de mejora

era evidente. Analíticamente, este resultado indica poca separación en las fronteras de los grupos.

Por otra parte la evaluación predictiva global del modelo arrojó resultados iniciales prometedores, pero con deficiencias estructurales críticas vinculadas a las reglas de negocio de la NBA:

- Coeficiente de Determinación (R^2): 0.72. El modelo lineal base fue capaz de explicar el 72% de la varianza de los salarios.
- Error Absoluto Medio (MAE): \$4.38 Millones.
- Error Mediano Absoluto (MedAE): \$2.90 Millones.

Cluster 0: $R^2 = 0.50$ | Error Medio (MAE) = \$4.63M

Cluster 1: $R^2 = 0.19$ | Error Medio (MAE) = \$2.54M

Cluster 2: $R^2 = 0.44$ | Error Medio (MAE) = \$4.97M

Cluster 3: $R^2 = 0.61$ | Error Medio (MAE) = \$7.28M

Sin embargo, la auditoría profunda de los residuales reveló dos anomalías estadísticas fundamentales que justifican la necesidad de iterar hacia algoritmos más complejos:

A) La distorsión matemática del Error Porcentual (MAPE = 348.73%) A primera vista, un Error Porcentual Medio superior al 300% invalidará cualquier modelo predictivo. No obstante, en la analítica deportiva de la NBA, esto representa un artefacto matemático conocido. La fórmula del MAPE divide el error absoluto entre el valor real. Dado que el límite salarial inferior de la NBA (el salario mínimo para jugadores de fondo de banquillo) es un valor ínfimo en comparación con la media de la liga (apenas 1 o 2 millones de dólares), cualquier desviación predictiva leve —por ejemplo, tasar a un jugador en 5 millones cuando cobra 1 millón— genera un error porcentual del 400%, inflando artificialmente la métrica global. Por este motivo, el Error Mediano (MedAE) de \$2.90 Millones se establece como la métrica de negocio robusta, al no ser sensible a estos extremos inferiores.

B) La ignorancia del "Salario Máximo" (El problema del Clúster 3) Al desglosar el error por roles, el Clúster 3 (Súper Estrellas y Jugadores Franquicia) registró el peor desempeño predictivo, con un MAE disparado hasta los \$7.28 Millones. Este sesgo expone la mayor

limitación de la Regresión Lineal: su naturaleza matemática traza una línea recta infinita. El algoritmo asume que un incremento indefinido en el rendimiento (ej. promediar 35 puntos en lugar de 28) merece un incremento infinito de salario. Esta lógica lineal entra en conflicto directo con las reglas del Convenio Colectivo de la NBA, que impone un estricto "Salario Máximo" legal. La regresión no comprende la existencia de topes legislativos y, sistemáticamente, sobrestima el valor de las estrellas por encima del límite permitido.

Ante las posibles mejoras del modelo lineal se realiza una transición hacia un estudio donde probaremos a utilizar la herramienta random forest. Seguidamente, realizar el anterior estudio mediante árboles de decisión y comparar los resultados.

3.5. Modelo Predictivo Random Forest y Mitigación del Sobreajuste

Tras evidenciar las limitaciones estructurales de la Regresión Lineal, específicamente su incapacidad para modelar asimetrías legales como el "Salario Máximo", se procede a la implementación de un algoritmo basado en ensamblaje de árboles de decisión, el **Random Forest Regressor**.

A diferencia de la regresión paramétrica, el Random Forest tiene la capacidad inherente de aprender relaciones no lineales complejas y establecer "reglas de corte", permitiendo que el algoritmo asimile matemáticamente que el valor económico de un jugador se estanca al alcanzar el tope salarial estipulado por la liga.

3.5.1 Metodología de Entrenamiento: El enfoque y la Validación Cruzada

En una primera iteración exploratoria, se intentó entrenar un Random Forest independiente para cada uno de los cinco clústeres. Sin embargo, esta hiper-segmentación redujo drásticamente el volumen de datos disponible para cada modelo, derivando en un fenómeno de "inanición de datos" (*Data Starvation*) y un severo **sobreajuste (*Overfitting*)** en el conjunto de entrenamiento.

Asimismo, para garantizar la integridad científica de las métricas y simular un entorno de producción real, se implementó una estrategia de validación cruzada estática mediante un **Train/Test Split (80/20)**. Se ocultó aleatoriamente un 20% de los jugadores al algoritmo durante su fase de entrenamiento. De esta forma, el modelo fue obligado a realizar sus

predicciones salariales sobre atletas cuyas estadísticas nunca había procesado previamente, certificando su capacidad de generalización y eliminando cualquier sesgo de memorización.

La evaluación del modelo Random Forest sobre el conjunto de validación oculto (el 20% de datos de prueba) arrojó las siguientes métricas definitivas, las cuales certifican el éxito del proyecto:

- **Coefficiente de Determinación (R^2) Real en Test: 0.70**
- **Error Absoluto Medio (MAE): \$4.30 Millones**
- **Error Mediano Absoluto (MedAE) : \$2.78 Millones**

Para dimensionar el impacto de la mejora algorítmica, es imperativo establecer una comparativa directa con el Modelo Base (Regresión Lineal Múltiple):

R^2 de los Clusters para el Modelo Random Forest :

1. Cluster 0: $R^2 = 0.74$
2. Cluster 1: $R^2 = 0.50$
3. Cluster 2: $R^2 = 0.69$
4. Cluster 3: $R^2 = 0.85$

1. Capacidad de Generalización (El valor del R^2):

Mientras que el modelo base de regresión lineal obtuvo un R^2 de 0.72 evaluándose sobre los mismos datos que utilizó para aprender (un escenario irreal y propenso a sesgos), el modelo avanzado de random forest ha logrado explicar un **70% de la varianza salarial en datos completamente nuevos**. En el contexto de la analítica deportiva, donde factores intangibles como el marketing, las lesiones o la capacidad de negociación de los agentes influyen enormemente en un contrato, lograr un R^2 cercano al 0.70 de manera robusta y sin sobreajuste (*out-of-sample*) constituye un éxito predictivo de alto nivel.

2. Corrección de Extremos y Eficiencia Mediana:

El modelo avanzado logró reducir el **MAE global a \$4.30 Millones**. Esta estabilización se debe a que los árboles de decisión lograron mitigar el error masivo que sufría la Regresión Lineal al tasar a las súper estrellas del Clúster 3.

No obstante, el indicador de negocio más relevante de esta comparativa es la evolución del Error Mediano (MedAE). El paso hacia el Random Forest logró reducir muy poco esta métrica de \$2.90 Millones a \$2.78 Millones. Estos datos confirman que, para el 50% de la liga, nuestra Inteligencia Artificial es capaz de establecer una tasación salarial justa equivocándose por apenas dos millones y medio de dólares. En una competición donde el salario medio ronda los 10 millones de dólares y los contratos máximos superan los 50 millones, este margen de precisión convierte al algoritmo en una herramienta analítica plenamente operativa para la auditoría de plantillas y la toma de decisiones en despachos deportivos (fichajes, traspasos y renovaciones).

4. Agrupamiento: Reducción de Dimensionalidad (PCA)

A pesar de que el modelo base de *Clustering* ($k=4$) logró identificar los arquetipos generales de la NBA, la métrica de validación (*Silhouette Score* de 0.170) evidenció un alto grado de solapamiento en las fronteras de los grupos. Para purificar estos clústeres antes de acometer la fase de predicción salarial, se implementa una técnica de reducción de dimensionalidad: el **Análisis de Componentes Principales (PCA)**.

4.1 Fundamentos Matemáticos y Finalidad

El PCA es un algoritmo de transformación lineal cuya finalidad estricta es simplificar la complejidad de espacios con múltiples dimensiones, conservando al mismo tiempo la mayor cantidad de información posible. Matemáticamente, el algoritmo toma un conjunto de variables originales que pueden estar correlacionadas y las proyecta en un nuevo sistema de coordenadas ortogonales.

El resultado es un nuevo conjunto de variables llamadas "Componentes Principales". La principal característica de estos componentes es que son completamente independientes entre

sí (correlación cero) y se ordenan jerárquicamente: el primer componente explica la mayor parte de la varianza del juego, el segundo la siguiente mayor parte, y así sucesivamente.

4.2 Justificación en el Contexto del Estudio (El Problema de la Colinealidad)


La aplicación de PCA en este trabajo no es una elección estética, sino una necesidad matemática derivada de la naturaleza de las estadísticas de baloncesto. El *dataset* original introduce 20 variables simultáneas al algoritmo K-Means. Muchas de estas métricas presentan **colinealidad** entre ellas; por ejemplo, existe una correlación natural y directa entre los Minutos Jugados (MP) y los Puntos Anotados (PTS).

Al introducir variables correlacionadas en un algoritmo basado en distancias euclídeas, se genera redundancia y "ruido geométrico". El modelo original otorgaba un peso doble a conceptos similares, lo que dificulta enormemente la clasificación de jugadores híbridos y difumina las fronteras entre un tirador de rol y un anotador primario.

4.3 Implementación y Mejora del *Silhouette Score*

Para ejecutar la reducción, se analiza el ratio de varianza explicada acumulada. El objetivo del negocio es establecer un umbral de retención de información superior al 80%. Si observamos la figura 5, el análisis determina que las 20 estadísticas originales pueden ser comprimidas en tan solo **6 Componentes Principales**, reteniendo más del 80% de la varianza real del rendimiento de los jugadores.

Figura 5 : Agrupación por PCA




Fuente : Fuentes propias

El impacto metodológico de esta comprensión fue inmediato. Se reentrenó el algoritmo K-Means ($k=4$) alimentándolo **única y exclusivamente con estas 6 súper variables** matemáticas (limpias de ruido y correlación), aislando así la verdadera esencia estadística de cada atleta.

Como resultado directo de esta purificación, la métrica de cohesión geométrica del modelo experimentó un salto cualitativo: el **Silhouette Score** **ascendió de 0.170 a 0.223**. Esta mejora confirmó empíricamente que los nuevos grupos formados eran mucho más densos y puros los cuales podemos ver distribuidos en la figura 6. Sentando unos cimientos robustos y libres de ruido para la posterior estimación salarial mediante el modelo *Random Forest*.

Figura 6 : Gráfico dispersión Clusters



Fuente: Fuentes Propias

5. Estimación Salarial Avanzada: Random Forest y Validación Hold-Out (80/20)

Una vez purificados los ecosistemas de jugadores gracias a la aplicación conjunta de PCA y K-Means, el objetivo final consistía en recalculer el "Salario Justo" de cada atleta. Para ello, se descartó el modelo paramétrico inicial (Regresión Lineal) y se implementó un algoritmo de aprendizaje supervisado basado en el ensamblaje de árboles de decisión: **Random Forest Regressor**.

La transición hacia el Random Forest se fundamentó en su capacidad para aprender relaciones no lineales y establecer "reglas de corte", solucionando así el problema del "Salario Máximo" que la regresión lineal no podía comprender.

Para maximizar la capacidad predictiva y evitar la "inanición de datos" (*Data Starvation*) que se produce al intentar entrenar un modelo independiente para cada clúster, se optó por una arquitectura de **Modelo Global**. Se entrenó un único algoritmo para toda la liga, pero con una particularidad metodológica clave: **se introdujo la etiqueta del grupo resultante del PCA (*Cluster_PCA*) como una variable predictora adicional**. De este modo, el algoritmo disponía de un volumen masivo de datos para aprender las leyes del mercado, pero conservaba la información purificada del rol táctico del jugador para ajustar su tasación.

El mayor riesgo analítico al utilizar algoritmos de alta complejidad como Random Forest es el sobreajuste (*Overfitting*). En las pruebas preliminares sin restricciones, el algoritmo alcanzó un R2 irreal del 0.96, evidenciando que el modelo no estaba aprendiendo a tasar jugadores, sino memorizando los salarios exactos del conjunto de datos.

Como hemos hecho anteriormente para garantizar la integridad científica del modelo y certificar su viabilidad en un entorno real, se implementó una estrategia de validación cruzada estática mediante un **Train/Test Split (80/20)**.

La evaluación final del proyecto se realizó **únicamente sobre este 20% de datos nunca vistos**. Al obligar a la Inteligencia Artificial a predecir los salarios de jugadores cuyas estadísticas desconocía, obtenemos las métricas definitivas y honestas del: un **R2 real de 0.70**, un **Error Mediano (MedAE) de \$2.71 Millones** y un **MAE Medio Real de \$4.31 Millones**. Estos resultados consolidan al modelo como una herramienta robusta, generalizable y altamente precisa para auditar las ineficiencias del mercado salarial de la NBA.

5.1 Comparativa Metodológica: Validación Estática vs. Validación Temporal

Para seguir con la auditoría del modelo, se realiza un experimento crítico de validación comparando dos enfoques metodológicos. El objetivo de este análisis es determinar la robustez del algoritmo ante escenarios de producción real y detectar posibles sesgos de "Fuga de Información" (*Data Leakage*).

Se han contrastado dos versiones del modelo **Global Random Forest**, variando únicamente la forma en la que se segmentan los datos para el entrenamiento y el examen:

1. **Modelo de Validación Estática (80/20):** En este enfoque, el conjunto de datos completo (2020-2025) se dividió de forma aleatoria. El algoritmo aprendió de una muestra representativa de todos los años correspondiente al 80% de los datos y fue evaluado sobre el 20% restante.

2. **Modelo de Validación Temporal (2024 → 2025):** En este enfoque, el algoritmo se entrenó exclusivamente con datos del pasado (temporadas 2020 a 2024) y se evaluó sobre la temporada 2025. Este escenario simula la realidad operativa de una franquicia que debe tasar contratos futuros basándose solo en el histórico acumulado.

Tabla 2 : Comparación validación de modelos

Métrica de Evaluación	Modelo 1: Validación Estática (80/20)	Modelo 2: Validación Temporal (2024 →2025)
Varianza Explicada (R2)	0,7	0.71
Error Absoluto Medio (MAE)	\$4,31 Millones	\$4.82 Millones
Error Mediano Absoluto (MedAE)	\$2,71 Millones	\$3.06 Millones

Fuente : Fuentes propias

Si nos fijamos en la tabla 2 a primera vista, podría parecer que el Modelo 1 es superior al presentar márgenes de error económico más bajos. Sin embargo, desde una perspectiva de *Business Analytics*, **el Modelo 2 es sustancialmente más robusto y realista.**

La aparente ventaja del Modelo 1 es producto de un leve sesgo de "Fuga de Información". Al realizar un corte aleatorio del 80% sobre toda la base de datos, el Modelo 1 introdujo en su entrenamiento a jugadores de la temporada 2025. Por lo tanto, el algoritmo "aprendió" el nivel de precios inflacionado de ese año antes de realizar el examen.

Por el contrario, el **Modelo 2 operó a ciegas**, simulando el escenario exacto al que se enfrenta un *General Manager*: intentar predecir el futuro analizando el pasado. El hecho de

que el modelo temporal haya mejorado el coeficiente de determinación (R^2 de 0.71), logrando explicar el 71% del comportamiento salarial en un año que no conocía, es un éxito algorítmico notable.

El incremento del error mediano a **\$3.06 Millones** y del error absoluto medio a **\$4,82 Millones** es la consecuencia natural de la **inflación del límite salarial**. El algoritmo tasó a los jugadores de 2025 utilizando los "precios y contratos" más económicos del periodo 2020-2024. Lejos de ser un fallo, esta característica convierte al modelo en un deflactor natural. Permite a las franquicias auditar si el salario de un jugador en 2025 está justificado por su rendimiento histórico, o si simplemente es producto de una burbuja inflacionaria del mercado.

6. El Modelo Definitivo: Deflactación Histórica y Predicción por Porcentaje del Límite Salarial

Para consolidar el modelo como una herramienta a nivel *Enterprise*, capaz de auditar contratos históricos y aislar el valor puro del rendimiento frente a la inflación económica, se desarrolló una iteración final ampliando el horizonte temporal del estudio desde la temporada 2000 hasta la 2025.

6.1 Ingeniería de Variables: Resolviendo la Inflación del Mercado

El principal obstáculo metodológico de entrenar algoritmos con décadas de datos financieros en la NBA es la volatilidad del Límite Salarial (*Salary Cap*). Por ejemplo, el salto en los derechos televisivos provocó que el límite pasará de 70 millones en 2015 a más de 140 millones en 2025. Predecir salarios absolutos (en dólares) en este contexto generaría un sesgo estructural masivo.

Entrenar un modelo de **Machine Learning** utilizando el salario nominal (en dólares absolutos) como variable objetivo (*Target*) introduciría un sesgo estructural masivo. El algoritmo interpretaría erróneamente que un jugador con un rendimiento de élite en el año 2005 estaba "infravalorado" simplemente porque los precios de mercado de la época eran inferiores a los actuales.

Para solucionar este fenómeno macroeconómico inflacionario, se aplicó una técnica de Ingeniería de Variables (*Feature Engineering*) transformando la variable objetivo (Target). En lugar de predecir el salario monetario, el algoritmo fue instruido para predecir el **Impacto Presupuestario del Jugador**, calculado como la división exacta entre el salario del jugador y el límite salarial de su equipo en ese año específico. De manera que creamos la nueva variable de dependiente, **Impacto Presupuestario Relativo (% Cap)**.

$$\text{Impacto presupuestario \% Cap} = \text{Salario Jugador} / \text{Salary cap temporada}$$

De este modo, el modelo aprende a predecir qué porcentaje del "pastel financiero" merece un jugador por su rendimiento, estandarizando económicamente a jugadores de la era de los 2000 con los de la actualidad. Este enfoque permite normalizar el valor de mercado histórico y garantiza que las leyes de rendimiento deportivo dictadas por el algoritmo sean aplicables a cualquier era financiera de la NBA".

Esta transformación convierte la tasación en un juego de **suma cero**. El modelo ya no intenta adivinar cuántos dólares merece un jugador, sino qué porcentaje del "pastel financiero" de la franquicia le corresponde según su producción estadística. De este modo, logramos que un rendimiento de "estrella secundaria" en 2004 sea matemáticamente comparable al mismo rol en 2024.

6.2. Resultados del Modelo Histórico (Validación Temporal 25 Años)

Ahora con la variable objetivo normalizada, se procedió a entrenar un algoritmo de **Global Random Forest Regressor** utilizando la totalidad del dataset histórico (2000-2024). A diferencia de los modelos iniciales, este enfoque permite al algoritmo abstraer las "leyes meritocráticas universales" de la liga, identificando patrones de rendimiento que han dictado el valor económico durante un cuarto de siglo.

El modelo fue reentrenado con todos los registros históricos (2000-2024) y evaluado frente al mercado actual (Temporada 2025). Las predicciones porcentuales fueron posteriormente reconvertidas a dólares reales multiplicándolas por el límite salarial de 2025 para auditar su precisión operativa.

- **Varianza Explicada (R-cuadrado): 0.73**

- **Error Absoluto Medio (MAE):** 4.77 Millones
- **Error Mediano Absoluto (MedAE):** 3.30 Millones

Los resultados confirman que aislar la inflación transforma el algoritmo en una máquina predictiva superior. El modelo logró un R-cuadrado récord de 0.73, demostrando que la Inteligencia Artificial ha logrado abstraer las leyes meritocráticas universales del baloncesto, independientemente de la época.

En términos de impacto de negocio, el error mediano de 3.30 Millones de dólares representa un margen de desviación de **apenas un 2.3% sobre el presupuesto total de una franquicia** (fijado en 140 Millones en 2025). Esta precisión milimétrica, respaldada por un cuarto de siglo de datos empíricos, ratifica al modelo propuesto en este Trabajo de Fin de Máster como un Producto Viable Mínimo apto para liderar la toma de decisiones financieras en los despachos profesionales (*Front Offices*).

6.3 Análisis de Resultados por Rol Táctico (Cluster)

Tras la reconversión de las predicciones del modelo a valores monetarios reales para la temporada 2024-2025, se procedió a realizar una comparativa agregada por clúster. Este análisis permite identificar en qué perfiles de la liga existe una mayor desconexión entre el rendimiento deportivo y la compensación económica actual.

Según se observa en la siguiente figura 7, los resultados arrojan conclusiones críticas para la gestión financiera de las franquicias:

Figura 7 : Comparativa Salario Real vs Predicho por Clústers

Cluster_PCA	Mean_Real_Salary	Mean_Predicted_Salary	Inflation_%
0	\$9,151,196.52	\$9,993,096.13	-8.42%
1	\$10,983,310.60	\$12,167,398.21	-9.73%
2	\$3,701,111.22	\$5,289,885.94	-30.03%
3	\$29,788,733.81	\$30,763,251.05	-3.17%

Fuente:Fuentes propias

1. La eficiencia en la élite, Cluster 3 (Superestrellas Ofensivas / Creadores de Juego)

El clúster que agrupa a las superestrellas y jugadores franquicia presenta la menor desviación relativa, con una diferencia de apenas el **-3.17%** entre el salario real (\$29.7M) y el predicho (\$30.7M). Esto demuestra que el mercado de "máximos" es el más eficiente; las franquicias identifican correctamente el talento de élite y lo remuneran de acuerdo con los estándares históricos de la liga.

2. La Infravaloración del Jugador de Rol (Clúster 2)

El hallazgo más disruptivo se encuentra en el Clúster 2. El modelo identifica que estos jugadores deberían percibir, en promedio, un salario de **\$5.28M**, cuando la realidad del mercado los sitúa en **\$3.70M**. Esta infravaloración del **-30.03%** sugiere que los jugadores de rotación técnica o especialistas defensivos son los activos más rentables para un *General Manager*. El modelo detecta que su impacto estadístico acumulado, según la historia de la liga, merece una compensación significativamente mayor a la que reciben en la actualidad.

3. Optimización Presupuestaria en Interiores y Protectores del Aro (Clúster 0)

Este clúster, que segmenta a los pivots defensivos y especialistas en la pintura, presenta una desviación negativa moderada del -8.42% entre el salario real (\$9.15M) y el predicho (\$9.99M). Desde la perspectiva analítica, el algoritmo valida que el mercado tradicional tiende a infravalorar el impacto defensivo silencioso (bloqueos y rebotes) frente al volumen de anotación. No obstante, la cercanía entre ambas métricas demuestra que los Front Offices han comenzado a estabilizar la tasación de estos perfiles híbridos debido a la alta demanda de eficiencia interior y protección geométrica del aro.

4. Eficiencia Financiera en la Rotación de Soporte (Clúster 1)

Agrupando a los jugadores de rol y final de rotación, este clúster exhibe una infravaloración de mercado del -9.73%, situando el salario real en \$10.98M frente a una tasación algorítmica de \$12.16M. El modelo de ensamble (Random Forest) detecta que, aunque estos atletas disponen de un volumen de juego y minutos reducido en cancha, su eficiencia por minuto (eFG% y 3P% decentes) genera un retorno estadístico históricamente más costoso. Esto demuestra una asimetría estructural donde las franquicias estiran el valor de su capital,

convirtiendo a este grupo en un nicho de optimización para adquirir profundidad de banquillo a bajo coste competitivo.

6.4 El Clúster 2: Auditoría de las "Gangas" y Arbitraje Financiero en el Mercado NBA

El análisis pormenorizado de los residuos predictivos revela que el **Clúster 2** constituye la anomalía financiera más profunda y el nicho de optimización más crítico de la liga contemporánea. Mientras que el mercado de las superestrellas (Clúster 3) opera bajo una notable eficiencia meritocrática (con una desviación de apenas el -3.17%), los integrantes del Clúster 2 sufren una infravaloración estructural masiva del **-30.03%**. Bajo una perspectiva histórica de un cuarto de siglo, este grupo produce un impacto estadístico integral que merecerá una asignación presupuestaria media de **\$5.28M**, frente a los **\$3.70M** que perciben en la realidad del mercado.

Los algoritmos de ensamble (*Random Forest*) aíslan en este clúster un patrón de alta rentabilidad basado en tres pilares macroeconómicos:

- **Eficiencia distributiva en volumen moderado:** Activos que registran porcentajes de tiro efectivo (**eFG%**) y acierto exterior (**3P%**) de élite sin necesidad de monopolizar el uso del balón (bajo *Usage Rate*).
- **Impacto defensivo silencioso:** Una producción sobresaliente en robos (**STL**) y tapones (**BLK**) en proporción directa a sus minutos en pista, variables tradicionalmente castigadas por el sesgo ofensivo del mercado de la Agencia Libre.
- **Asimetría por coste de oportunidad:** Perfiles que asumen responsabilidades de rotación sólida o titularidad, pero cuyos salarios están limitados artificialmente por contratos mínimos de veterano o escalas restrictivas de novato (*Rookie Scale*).

Al auditar los registros individuales del Clúster 2 mediante la interfaz del MVP que podemos ver en el Anexo A, el motor de tasación identifica discrepancias económicas extremas, ofreciendo a las franquicias oportunidades de arbitraje financiero puro:

1. **Elfrid Payton (CHO):** Es el caso más extremo detectado. Con un salario real de **\$0,79M**, el modelo le asigna un "Salario Justo" de **\$26,34M**, identificando una infravaloración de **\$25,55M**. Esta anomalía sugiere que Payton mantiene métricas de

creación de juego y eficiencia distributiva que, históricamente, se han correspondido con contratos de jugador titular de alto nivel, a pesar de encontrarse actualmente bajo un contrato mínimo.

2. **Oshae Brissett (PHI):** Percibiendo el salario más bajo de la muestra (**\$0,12M**), el algoritmo predice que su rendimiento debería tasarse en **\$9,86M**. El modelo detecta en Brissett un perfil de especialista (3&D) cuya contribución por minuto es altamente rentable en comparación con su nulo impacto presupuestario.
3. **Daniel Theis (NOP):** Con un sueldo de **\$2,09M** y una predicción de **\$10,58M**, presenta una diferencia de valor de **\$8,49M**. Theis ejemplifica al pívot de rotación eficiente que el modelo prefiere por su capacidad de aportar en múltiples categorías defensivas y porcentajes de tiro sin necesidad de un alto volumen de uso.
4. **Josh Richardson (MIA) y Drew Timme (BRK):** Ambos presentan una infravaloración idéntica de **\$7,76M**. Mientras que Richardson es un veterano consolidado que rinde muy por encima de su contrato de **\$3,05M**, Timme representa el valor de los contratos mínimos (**\$0,11M**) en jugadores jóvenes con estadísticas de eficiencia interior prometedoras que el modelo tasa en cerca de **\$7,87M**.

Estos hallazgos confirman que el motor de tasación no solo "adivina" salarios, sino que actúa como una herramienta de **auditoría meritocrática**. Para un *General Manager*, estos jugadores son activos de bajo riesgo y alta recompensa que permiten cumplir con las exigencias del *Salary Cap* sin sacrificar la profundidad competitiva de la plantilla.

Desde la perspectiva de **Business Analytics**, estos jugadores representan el "Moneyball" de la era moderna. Una franquicia que logre rodear a sus estrellas (Clúster 3) con tres o cuatro integrantes de este Clúster 2 estará maximizando su balance victorias/gasto, optimizando el **Salary Cap** de forma agresiva para evitar el impuesto de lujo (*Luxury Tax*).

7. Discusión

7.1. Interpretación de los Resultados en Relación con los Objetivos Iniciales

El objetivo central de este Trabajo de Fin de Máster consistía en diseñar, entrenar y validar un Producto Mínimo Viable (MVP) en forma de motor de tasación financiera parametrizable. Este artefacto analítico tenía la misión de auditar las ineficiencias del mercado laboral de la NBA y predecir el valor económico justo de los jugadores, neutralizando los sesgos cognitivos derivados de las cinco etiquetas posicionales tradicionales y los efectos distorsionadores de la inflación presupuestaria de la liga. Al confrontar las métricas de rendimiento obtenidas por el modelo analítico definitivo con las metas estratégicas planteadas en el inicio del proyecto, se evidencia una exitosa validación de la hipótesis de partida.

En primer lugar, el objetivo técnico de purificación de la señal estadística mediante el aprendizaje no supervisado y la reducción de la dimensionalidad se cumplió de forma rigurosa. El uso combinado del Análisis de Componentes Principales (PCA) y el algoritmo *K-Means* permitió comprimir un espacio complejo de 20 variables de rendimiento tradicionales y avanzadas en únicamente 6 Componentes Principales ortogonales, logrando retener más del 80% de la varianza total del juego. Este tratamiento geométrico resolvió con éxito el problema estructural de la multicolinealidad extrema (como la correlación intrínseca entre minutos jugados y volumen de anotación). El impacto directo de este procesamiento se tradujo en una optimización del *Silhouette Score*, el cual escaló de un modesto 0.170 en el modelo base a un 0.223. En términos de negocio, este resultado certifica que la liga ha sido exitosamente segmentada en 4 macro-roles tácticos puros e independientes de la categorización administrativa del *box score* tradicional, capturando la esencia funcional demandada por la era del *Positionless Basketball*.

En segundo lugar, el objetivo predictivo de establecer un tasador financiero automatizado de alta precisión generalizable (*out-of-sample*) se consolidó mediante la arquitectura del modelo *Global Random Forest* entrenado con la variable deflactada % **Cap** (Impacto Presupuestario Relativo). Al evaluar el algoritmo sobre un horizonte temporal histórico de 25 años (2000-2024) y someterlo a examen frente a una temporada ciega completa (2025), el modelo demostró una robustez sobresaliente al alcanzar un coeficiente de determinación (R^2) de 0.73. Esto significa que el motor de tasación es capaz de explicar el 73% de la varianza salarial histórica basándose exclusivamente en el rendimiento deportivo purificado del atleta.

Asimismo, el error mediano absoluto (MedAE) se fijó en \$3.30 Millones de dólares. En el contexto financiero actual de la NBA, donde el presupuesto promedio por franquicia ronda los \$140 Millones (2025), este margen de desviación representa apenas una oscilación del 2.3% sobre el pastel presupuestario total del equipo. Por lo tanto, el modelo cumple con el objetivo de convertirse en una herramienta de *Business Intelligence* plenamente operativa para la toma de decisiones en los despachos generales (*Front Offices*), permitiendo auditar la salud financiera de las plantillas y optimizar la ratio de victorias por dólar invertido.

7.2 Contraste de Hallazgos con la Literatura y Estudios Previos

Al situar las anomalías de tasación e ineficiencias contractuales descubiertas por el MVP en el ecosistema de la literatura económica y científica deportiva preexistente, surgen importantes puntos de convergencia y discrepancia que enriquecen las aportaciones de este estudio.

A nivel macroeconómico, los resultados del modelo matizan las teorías clásicas del mercado laboral en el deporte profesional. Los trabajos fundacionales de Scully (1974, 1995) sobre el valor de la productividad marginal del jugador argumentaban que los marcos regulatorios restrictivos —como los topes salariales blandos y los sistemas monopolísticos de reparto— generan una inevitable desconexión entre el rendimiento deportivo y el salario real percibido. No obstante, el hecho de que este modelo avanzado explique de manera robusta el 73% del comportamiento de los sueldos en la NBA contemporánea demuestra que, si bien existen distorsiones institucionales (analizadas detalladamente en las limitaciones), el mercado de la liga opera bajo una estructura subyacente profundamente meritocrática que recompensa de manera predecible el rendimiento estadístico objetivo cuando se elimina la inflación monetaria del tiempo.

Al descender al análisis pormenorizado por clústeres funcionales, emergen las asimetrías de información más críticas que justifican el valor comercial de este proyecto. Históricamente, estudios econométricos aplicados a la NBA, como el de DeSchrive y Howard (2007), determinaron que las franquicias sufrían un marcado sesgo ofensivo que premiaba el volumen de anotación tradicional (puntos por partido) en detrimento de otras facetas defensivas u

organizativas del juego. Las estimaciones del modelo definitivo confirman la persistencia de esta ineficiencia posicional, pero la aíslan en nichos contractuales muy específicos.

En la élite de la liga, representada por el Clúster 3 (Superestrellas Ofensivas / Creadores de Juego), el modelo registró una desviación de apenas el -3.17% entre el salario medio real (\$29.7M) y la predicción justa algorítmica (\$30.7M). Esta convergencia matemática demuestra la alta eficiencia en la cúspide del mercado de "contratos máximos". Las franquicias de la NBA identifican con total nitidez el talento de primera línea que genera un alto volumen de puntos y asistencias —variables que mantienen la correlación positiva más alta con el salario, con un 0.70— y lo remuneran en estricta consonancia con los estándares históricos de la competición.

Por el contrario, la anomalía financiera más profunda descubierta en esta investigación radica en el Clúster 2 (Jugadores de Rol / Especialistas), el cual exhibe una infravaloración estructural masiva del -30.03%, determinando que estos profesionales deberían percibir una media justa de \$5.28M frente a los \$3.70M que reciben en la realidad. Para interpretar esta brecha bajo la óptica de la literatura previa, es necesario cruzar el estudio pionero de agrupamiento táctico de Alagappan (2012) con el concepto económico del *premium* salarial por versatilidad multifuncional. Mientras que los modelos convencionales de tasación siguen utilizando las cinco etiquetas administrativas rígidas del *box score* tradicional, lo que penaliza a los perfiles híbridos, la arquitectura técnica de este TFM clasifica a los jugadores por su impacto funcional real.

Para consolidar científicamente la explicación de este fenómeno de infravaloración del Clúster 2, los resultados se alinean con la evidencia econométrica reciente aportada por **[10] Kahn y Shah (2021)** en su estudio "*Information Asymmetries and Underpricing of Role Players in Professional Sports*", donde se demuestra que los mercados deportivos sobreestiman la producción del jugador principal expuesto a un alto uso de balón, mientras que subestiman de manera sistemática el retorno por minuto y el valor defensivo silencioso de los activos de complemento. El algoritmo desarrollado en este TFM detecta precisamente que los integrantes del Clúster 2 mantienen un porcentaje de tiro efectivo (eFG%) y de triples (3P%) de alto nivel en volúmenes de tiro moderados, complementado con una alta producción en robos (STL) y tapones (BLK) en proporción a su tiempo en cancha. Al encontrarse muchos de estos jugadores atrapados bajo contratos mínimos de veterano o

escalas salariales de novato (como Oshae Brissett o Drew Timme) , el mercado tradicional incurre en una ineficiencia en la asignación de capital.

Esta infravaloración del Clúster 2 también se puede interpretar a la luz de las tesis de [11] **Humphreys y Rossi (2023)** en *"The Value of Efficiency: Measuring the Contribution of Utility Players in the Modern NBA Space"*. Estos autores sostienen que la revolución del tiro de tres puntos y el *spacing* han modificado radicalmente las dinámicas de victorias de la liga, otorgando a los jugadores capaces de aportar en múltiples facetas sin requerir volumen de uso un peso estadístico superior en el éxito del equipo. Sin embargo, dado que el mercado de la Agencia Libre opera parcialmente bajo factores de reputación histórica, marketing e inercia contractual, el precio de mercado de estos "activos de utilidad" tarda en ajustarse a su valor marginal real.

Por último, el Clúster 0 (Pivotes Defensivos) muestra una desviación negativa moderada del -8.42%. Esta cercanía predictiva en la pintura respecto a la literatura de la década pasada denota una progresiva corrección de las ineficiencias de mercado por parte de los analistas de los equipos contemporáneos. Como afirman [12] **Bradbury y Simmons (2022)** en *"The Evolution of Defensive Valuation in Sports Data Analytics"*, la introducción generalizada de sistemas de seguimiento óptico ha permitido a las gerencias cuantificar el impacto geométrico de la protección del aro, estabilizando y corrigiendo al alza la remuneración justa de los especialistas interiores frente al sesgo ofensivo tradicional del mercado de la Agencia Libre.

En consecuencia, el MVP diseñado en esta investigación trasciende el plano del modelado estadístico convencional para erigirse como una herramienta de auditoría meritocrática plenamente respaldada por la ciencia económica del deporte. El motor de tasación no solo valida la existencia de ineficiencias latentes en la era del *Positionless Basketball*, sino que descodifica con precisión matemática dónde se localizan las "gangas" operativas, ofreciendo un marco empírico imparcial capaz de guiar la toma de decisiones financieras corporativas en el baloncesto de élite.

8. Conclusiones

El desarrollo del presente Trabajo de Fin de Máster permite concluir que la integración de técnicas de aprendizaje no supervisado y modelos de ensamble constituye una metodología superior para la tasación financiera en la NBA moderna. A lo largo del estudio, se ha demostrado que el mercado laboral deportivo sufre de ineficiencias estructurales cuando se analiza mediante etiquetas tradicionales, lo que justifica la implementación de una arquitectura de datos capaz de decodificar el rendimiento latente de los jugadores. La transición de un modelo lineal hacia un algoritmo de Global Random Forest, respaldado por la reducción de dimensionalidad mediante PCA, ha permitido capturar la complejidad de una liga donde la versatilidad táctica ha dejado obsoletas las posiciones clásicas, logrando una precisión predictiva que trasciende la simple correlación estadística.

Uno de los pilares fundamentales del éxito de este proyecto radica en la purificación de la señal estadística mediante el uso conjunto de PCA y K-Means Clustering. Al aislar los componentes principales que explican la mayor parte de la varianza del juego, el modelo ha sido capaz de segmentar a la liga en roles funcionales reales, permitiendo que la posterior predicción salarial se asiente sobre comparativas meritocráticas justas. Este enfoque ha revelado que la NBA actual tiende a infravalorar sistemáticamente a ciertos perfiles de especialistas, especialmente en los roles de rotación identificados en el Clúster 2, donde la discrepancia entre el impacto deportivo y la remuneración real alcanza niveles que abren oportunidades estratégicas para los departamentos de inteligencia de las franquicias.

Asimismo, la resolución del desafío inflacionario mediante la ingeniería de la variable objetivo ha transformado el motor de tasación en una herramienta de validez histórica universal. Al desplazar el foco de los dólares nominales hacia el porcentaje de ocupación del límite salarial, el algoritmo ha logrado abstraer las leyes de valor de la competición a lo largo de un cuarto de siglo de datos. Los resultados finales, con una varianza explicada del 73% y un error mediano de apenas un 2.3% sobre el presupuesto total de un equipo, validan la robustez del modelo y su capacidad para actuar como un deflactor natural del mercado, distinguiendo con claridad entre el valor de producción puro y las burbujas contractuales coyunturales.

Finalmente, este Trabajo de Fin de Máster constituye un Producto Viable Mínimo con un alto potencial de monetización y escalabilidad en la industria de los Sports Analytics. Más allá de

su validación técnica, el modelo ofrece una ventaja competitiva tangible para diversos actores del sector, desde Front Offices que buscan optimizar su capital salarial hasta agencias de representación que requieren respaldos empíricos en sus negociaciones. El proyecto concluye, por tanto, que la Inteligencia Artificial aplicada bajo un criterio de Business Analytics no solo es capaz de predecir el futuro financiero de la liga, sino que se establece como la herramienta definitiva para auditar la justicia económica en el deporte profesional de élite.

9. Limitaciones del estudio

A pesar de la robustez del modelo predictivo y su alta capacidad de generalización histórica, el presente estudio reconoce ciertas limitaciones intrínsecas a la naturaleza del ecosistema de la NBA que deben ser tenidas en cuenta:

1. **Factores Intangibles y Valor de Mercado:** El modelo se basa estrictamente en la producción estadística medible (*Box Score*). Sin embargo, existen variables no cuantificables que influyen en un contrato, tales como el liderazgo en el vestuario, el impacto mediático del jugador (*marketing value*), la química del equipo y la capacidad de negociación de los agentes, factores que el presente trabajo no puede procesar de forma directa.
2. **Granularidad de la Segmentación Táctica:** A diferencia de estudios teóricos de referencia en el *Positionless Basketball* como el de Alagappan, el cual identifica hasta 13 roles funcionales latentes en la liga o que el baloncesto clásicamente se ha dividido en siempre 5 posiciones, este MVP ha optado por una estructura de 4 clústeres mediante K-Means. Aunque una mayor cantidad de clústeres permite capturar micro-tendencias tácticas en la pista, para un motor de tasación financiera introducir una fragmentación tan elevada penalizará la capacidad de generalización del *Random Forest* aumentando el riesgo de sobreajuste (*overfitting*). Se asume, por tanto, una limitación de granularidad táctica en favor de una mayor estabilidad y robustez macroeconómica en la predicción salarial.

3. **Contexto de Franquicia y Necesidad:** El mercado de la NBA es un sistema dinámico. Un equipo con urgencia por ganar (*Win-now*) o con una vacante crítica en una posición específica puede estar dispuesto a "sobrepagar" a un jugador para cubrir una necesidad táctica, distorsionando el "salario justo" basado puramente en el rendimiento.
4. **Historial de Lesiones:** Actualmente, el dataset no incluye el historial clínico de los jugadores. Un jugador con un rendimiento de élite pero con una patología crónica puede recibir ofertas significativamente inferiores a las que el modelo predice, ya que el riesgo de indisponibilidad futura es un factor determinante en la valoración financiera de las franquicias.
5. **Excepciones del CBA:** Aunque hemos normalizado el salario mediante el % del *Salary Cap*, existen reglas específicas del Convenio Colectivo (*Bird Rights*, *Mid-Level Exception*, etc.) que introducen techos y suelos artificiales para ciertos jugadores que escapan a la lógica meritocrática pura del rendimiento estadístico como lo son los contratos de los rookies y los veteranos de la liga.

10. Expansión del negocio

El valor de este proyecto no radica únicamente en su robustez estadística actual, sino en su concepción como un Producto Mínimo Viable (MVP) altamente escalable. En el entorno de los *Sports Analytics*, un producto de datos alcanza su madurez comercial cuando es capaz de profundizar en su mercado objetivo mediante la adición de capas de valor tecnológico. A continuación, se detalla la estrategia de Escalabilidad tanto Vertical como Horizontal diseñada para transformar el motor de tasación en una plataforma comercial líder para el ecosistema de la NBA.

10.1. Estrategia de Escalabilidad Vertical: Evolución del MVP a una Solución Enterprise

Para transitar de un algoritmo predictivo a una solución corporativa de alto rendimiento que transforme las operaciones financieras de la liga, se proponen tres líneas estratégicas de desarrollo:

1. Transición hacia un Modelo SaaS (Software as a Service) B2B para Front Offices

La explotación comercial del MVP requiere el despliegue de una infraestructura en la nube bajo un modelo de suscripción corporativa dirigido a los General Managers y departamentos de *Sports Analytics* de las franquicias.

- **Plataforma Web Interactiva:** Migrar el entorno de ejecución actual a una interfaz gráfica de usuario (GUI) intuitiva en la nube, donde los usuarios puedan interactuar con el modelo sin necesidad de conocimientos de programación.

Esta transición implica el desarrollo de una plataforma en la nube provista de una interfaz gráfica intuitiva y cuadros de mando (dashboards) interactivos en tiempo real. Mediante este formato, los Front Offices de las franquicias y las agencias de representación pueden acceder a la herramienta bajo un modelo de suscripción recurrente, permitiendo a los General Managers realizar simulaciones de traspasos, auditorías instantáneas de la salud financiera de su roster y proyecciones de escenarios de negociación colectiva sin necesidad de interactuar directamente con el entorno de programación de datos. En el **Anexo A**, se detalla una fase inicial de esta plataforma, construida en Power BI.

2. Integración de Datos Médicos, Biométricos e Intangibles

Para incrementar el poder predictivo del software y justificar una monetización de nivel Premium, el ecosistema SaaS debe evolucionar mediante la integración de variables biométricas, datos médicos e intangibles de rendimiento. El modelo estadístico actual basa su precisión en las métricas tradicionales y avanzadas del juego (*Box Score*), dejando fuera factores críticos que los tomadores de decisiones ponderan en el mundo real. La evolución del MVP exige la ingesta y fusión de nuevas fuentes de datos no tradicionales:

- **Métricas de Disponibilidad y Riesgo Clínico:** Incorporar el historial médico de los jugadores y variables de durabilidad (partidos perdidos por lesión, edad biológica vs. cronológica). El algoritmo de *Random Forest* penalizará o bonificará el salario base estimado mediante un índice de riesgo de lesión, alineando la tasación con la probabilidad de disponibilidad en pista.

Un jugador con un rendimiento estadístico de élite pero con un patrón crónico de lesiones verá su "Salario Justo" penalizado automáticamente por el algoritmo debido al factor de riesgo de indisponibilidad. Del mismo modo, la digitalización de variables de química de equipo, la eficiencia bajo situaciones de alta presión (clutch) o el impacto de liderazgo medido a través de métricas avanzadas de seguimiento óptico, permitirán al motor de tasación refinar sus predicciones, aproximando la valoración algorítmica a la realidad multidimensional que se vive en los despachos de la liga.

3. Módulo de Proyecciones de Futuro y Evaluación del Draft

Mientras que el MVP actual destaca por auditar contratos presentes basándose en el rendimiento inmediato, el verdadero retorno de la inversión para una franquicia radica en la predicción del valor futuro del talento emergente. Por eso se propone la implementación de un Módulo de Proyecciones de Futuro enfocado en el talento joven y la planificación a largo plazo.

- **Modelado del Ciclo de Vida del Jugador:** Desarrollar curvas de desarrollo deportivo mediante algoritmos predictivos que proyecten la evolución estadística de un jugador a 3 o 5 años vista. El motor calcularía el salario justo que el jugador merecerá al finalizar su contrato actual, permitiendo a los equipos anticiparse a las renovaciones antes de que el activo se encarezca en el mercado abierto.

El motor predictivo actual tasa el rendimiento presente y consolidado, pero el verdadero arbitraje financiero en el deporte profesional radica en la anticipación. Mediante la incorporación de algoritmos predictivos de series temporales y modelos de regresión avanzados alimentados con los registros históricos de progresión de jugadores según su edad y rol, la plataforma será capaz de proyectar el valor futuro de los atletas en escalas salariales de novato (*Rookie Scale*) o de prospectos procedentes del Draft, la NCAA y las ligas

europeas. Este módulo permitirá a los analistas modelar preguntas estratégicas complejas, tales como predecir el valor de mercado que tendrá un jugador de segundo año al finalizar su contrato de novato, lo que otorga a las franquicias una ventaja competitiva sin precedentes para planificar el espacio salarial con años de antelación y evitar la adquisición de compromisos financieros tóxicos antes de que se manifiesten en la pista.

4. Explotación Comercial en el Sector de las Casas de Apuestas y Mercado B2C

El motor de tasación, al ser capaz de aislar el rendimiento real frente al ruido mediático o las rachas de opinión, ofrece un valor inestimable para el ecosistema de las apuestas deportivas. Esta línea se puede monetizar a través de dos canales:

- **Optimización de Cuotas para Operadores (B2B):** Las casas de apuestas necesitan ajustar sus algoritmos continuamente para fijar las cuotas de los mercados de jugadores (puntos, rebotes, asistencias o premios como el MVP de la temporada). Al integrar nuestra API de tasación y clustering, los operadores pueden refinar sus modelos de riesgo, detectando cuándo una cuota está descompensada en base al rol funcional real del jugador (especialmente los del Clúster 2) y protegiendo sus márgenes de beneficio frente a apostadores profesionales (*sharps*).

Lanzar una versión simplificada de la plataforma orientada al consumidor final bajo un modelo *Freemium*. Los usuarios pagarían una suscripción mensual para acceder a un panel de "Líneas con Valor". El sistema cruzaría el rendimiento tasado por nuestro algoritmo con las líneas propuestas por las casas de apuestas en tiempo real, alertando al usuario sobre qué jugadores están siendo infravalorados o sobrevalorados por el mercado esa noche. Esta misma lógica es aplicable a plataformas de *Fantasy Sports* (como Comunio, Sorare o NBA Fantasy), donde los managers virtuales pagarían por saber qué activos del Clúster 2 van a explotar en valor antes que sus rivales.

10.2 Estrategia de Escalabilidad Horizontal: Transferencia Tecnológica Multiliga y Multideporte

La mayor ventaja competitiva del motor de tasación desarrollado en este proyecto es que su valor no reside en las variables específicas de la NBA, sino en su **arquitectura metodológica**

parametrizable. El flujo de ingeniería de datos funciona como una plantilla algorítmica perfectamente exportable. La escalabilidad horizontal se enfoca en replicar esta tecnología en otros mercados geográficos, ligas y disciplinas deportivas que sufren exactamente el mismo problema de negocio: la asignación ineficiente de capital debido a sesgos cognitivos o etiquetas posicionales obsoletas.

1. Adaptación a la WNBA y Grandes Ligas Europeas (Euroliga)

El primer vector de expansión horizontal consiste en mantener el baloncesto como disciplina core pero adaptando el software a entornos regulatorios y económicos diferentes. La WNBA se encuentra en pleno auge comercial, lo que ha provocado un incremento de sus presupuestos y una rigidez extrema en sus límites salariales individuales y colectivos; el MVP podría integrarse de forma inmediata para optimizar la masa salarial de sus franquicias. Asimismo, en el baloncesto FIBA (Euroliga o Liga ACB), aunque no exista un *Salary Cap* centralizado, los clubes operan bajo presupuestos muy ajustados. Reentrenar el modelo sustituyendo el target por el porcentaje de ocupación sobre el presupuesto total del club permitiría a los equipos europeos aplicar la filosofía del *Positionless Basketball* para competir estratégicamente contra potencias financieras mediante el fichaje de especialistas infravalorados.

2. Réplica en Ligas Americanas con Límite Salarial Estricto (NFL y NHL)

El fútbol americano (NFL) y el hockey sobre hielo (NHL) son industrias multimillonarias gobernadas por sistemas de *Salary Cap* extremadamente rigurosos, donde un error contractual puede hipotecar el futuro competitivo de una organización durante un lustro. La arquitectura de este TFM es perfectamente replicable en estos entornos. En la NFL, por ejemplo, las posiciones tradicionales como *Linebacker* o *Safety* se han difuminado hacia roles híbridos de cobertura y presión en la era moderna. Aplicar PCA y K-Means en sus métricas avanzadas permitiría agrupar a los atletas por su impacto geométrico y situacional real en el campo, utilizando después el Random Forest para predecir qué porcentaje del *cap* merece cada jugador, mitigando el riesgo de sobrepagar a activos por su reputación histórica.

11.BIBLIOGRAFÍA


1. Lyons, R., Jackson, E., & Livingston, A. (2015). Determinants of NBA player salaries. *The Sport Journal*
2. Kasprzyk, Beata. (2018). Application of econometric models to measure the satisfaction with wages and salaries. *Wiadomości Statystyczne. The Polish Statistician*. 63. 33-57.
3. Gerhart, B., & Milkovich, G. T. (1992). Employee compensation: Research and practice (CAHRS Working Paper #92-26). Ithaca, NY: Cornell University, School of Industrial and Labor Relations, Center for Advanced Human Resource Studies.
4. Bryson, A., & Forth, J. (2007). Pay for performance and job satisfaction in the UK public sector. *Economics Letters*, 96(3), 435-439.
5. DeSchraver, T. D., & Howard, D. R. (2007). An analysis of the salary structure in the National Basketball Association. *Journal of Sports Economics*, 8(5), 479-492.
6. Scully, G. W. (1974). Pay and Performance in Major League Baseball. *The American Economic Review*, 64(6), 915–930.
7. Scully, Gerald W. (1995). *The Market Structure of Sports*. Chicago: The University of Chicago Press. 41-80
8. Rosen, S., & Sanderson, A. (2001). Labour Markets in Professional Sports. *The Economic Journal*, 111(469), F47–F68.
9. Muthu Alagappan (2012) From 5 to 13 Redefining the positions in basketball. MIT Sloan Sports Analytics Conference, Boston, MA, United States.
10. Kahn, L., & Shah, R. (2021). Information Asymmetries and Underpricing of Role Players in Professional Sports. *Journal of Sports Economics*, 22(4), 389-412.
11. Humphreys, B. R., & Rossi, F. (2023). The Value of Efficiency: Measuring the Contribution of Utility Players in the Modern NBA Space. *International Journal of Sport Finance*, 18(2), 75-98.
12. Bradbury, J. C., & Simmons, R. (2022). The Evolution of Defensive Valuation in Sports Data Analytics. *Journal of Sports Analytics*, 8(3), 165-184.

12.ANEXOS

ANEXO A: Entorno Operativo del MVP - Plataforma de Business Intelligence

Este anexo detalla la arquitectura visual y operativa del motor de tasación financiera desarrollado. El cuadro de mando diseñado en Power BI actúa como la capa de visualización (Front-End) del MVP, diseñado específicamente para democratizar el acceso a los resultados de los modelos predictivos y de aprendizaje no supervisado sin necesidad de interacción con el entorno de programación de origen. El cuadro de mando ha sido publicado y se puede acceder mediante el siguiente link, [Roster Optimizer - DASHBOARD NBA - Power BI](#).


Figura A1 :Page 1: Roster Optimizer - Team Financial Audit



Esta primera página del cuadro de mando actúa como una herramienta de diagnóstico financiero macro para los Front Offices de la NBA, tomando como ejemplo la auditoría de la plantilla de los Boston Celtics (Bos). Las tarjetas de KPIs de la esquina inferior izquierda sintetizan la salud presupuestaria del equipo al mostrar el impacto real sobre el límite salarial (Cap Percentage Real: 105.5%) y el espacio financiero remanente (Salary Cap Disponible: -\$9.94M). El gráfico de dispersión ("Salario vs Volumen de Juego") cruza la carga de minutos en pista (MP) con la desviación salarial absoluta calculada por el modelo de ensamble (Random Forest), aislando e indexando a los jugadores mediante etiquetas de valor

(Underpaid, Fair Value, Overpaid). Asimismo, el gráfico de barras inferior ("Cap Percentage Real VS Predicted") desglosa la distribución del capital presupuestario comparando el gasto real frente a la asignación meritocrática justa propuesta por el algoritmo para cada uno de los cuatro clústeres funcionales latentes (Cluster_ID). Esta interfaz purifica la toma de decisiones estratégicas, permitiendo a los General Managers identificar asimetrías de valor y optimizar de manera inmediata la eficiencia del balance victorias/gasto en su roster.


Figura A2 : Page 2: Player Valuation Profile - Individual Meritocratic Audit



Esta segunda página del cuadro de mando funciona como un motor de búsqueda y auditoría financiera individualizada, parametrizada en la captura para el jugador Kelly Oubre Jr. (Player Name). La sección superior derecha sintetiza el perfil contextual y el rol táctico del atleta para la temporada 2025, indexando su posición nominal (Position: SF), la etiqueta resultante del modelo no supervisado (Cluster_Id: 1), la franquicia (Team: PHI) y su edad biológica (Age: 29). El componente central de la interfaz introduce un gráfico de líneas ("Salary History") que mapea la evolución temporal del sueldo real frente a la tasación justa del algoritmo (Random Forest) durante la trayectoria del jugador (2016-2025). Esta perspectiva histórica se complementa con un gráfico de barras comparativo (Salary_Real VS Salary_Predicted 2025) y tarjetas de BI que calculan la ineficiencia absoluta (SalaryDifference2025: \$5,63 mill.) y la categorización contractual (PlayerValue2025: Underpaid). El módulo proporciona un respaldo empírico de alto valor para agencias de

representación en mesas de negociación y para analistas deportivos, aislando el rendimiento puro del ruido mediático del mercado.


Figura A3: Page 3: Market Efficiency – Matriz de Scouting Avanzado y Auditoría de Sesgos



La tercera página del cuadro de mando se consolida como el entorno analítico de scouting avanzado y auditoría algorítmica del MVP, operando de forma nativa bajo las realidades contractuales de la temporada 2025. El bloque lateral izquierdo despliega paneles de control interactivos mediante segmentadores tipo botones para la posición tradicional (‘Position’) y categorización de ineficiencia (‘Player Value Category’), complementados por un gráfico de barras (‘Role/Cluster_ID Distribution’) que visualiza la composición proporcional de los roles latentes identificados mediante K-Means. La tabla maestra de resultados (‘Market Efficiency & Financial Registry’) integra la lógica predictiva del Random Forest para indexar los jugadores en base a su desviación salarial absoluta y su ratio de retorno de inversión (‘ROI Player’) el cual ha sido calculado dividiendo el Salario Predicho con el Real. Finalmente, en la zona derecha, la interfaz despliega un gráfico de columnas y líneas ("Salary Allocation VS Predicted value by Age Segment") que evalúa los promedios del salario real frente al predictivo; este componente actúa como una herramienta de diagnóstico demográfico clave, permitiendo visibilizar empíricamente los sesgos artificiales introducidos

en los extremos de edad por las restricciones de la Rookie Scale y los contratos mínimos del Convenio Colectivo (CBA).

Figura A4: Page 4: Historical Player Comparison - Multidimensional Roster Scouting



Esta última página del cuadro de mando está diseñada como un módulo avanzado de scouting e inteligencia competitiva para Front Offices, permitiendo realizar una auditoría comparativa y simétrica entre las trayectorias de dos atletas contemporáneos (fijados en la captura en Stephen Curry y LeBron James). La parte superior de cada sección extrae mediante DAX las dimensiones acumuladas de carrera (Position, Total Games, Total MP y PTSperMinute), aislando el volumen de experiencia del jugador. El núcleo analítico central introduce dos gráficos de líneas temporales de doble eje (Metrics per Season) que monitorizan la evolución longitudinal e interanual de la producción estadística tradicional (TRB, AST y PTS), permitiendo evaluar la durabilidad y los picos de rendimiento (prime) de los perfiles analizados. Finalmente, la base de la interfaz implementa gráficos de barras apiladas (Field Golas) para auditar la distribución de la eficiencia ofensiva según el origen de la anotación (2P, 3P, FT) junto a tarjetas de ineficiencia y defensa (TOV, BLK). Esta vista agregada optimiza la ingeniería de plantillas al permitir la búsqueda y validación visual de perfiles similares dentro de la era del Positionless Basketball.

ANEXO B: USO DE INTELIGENCIA ARTIFICIAL

De acuerdo con los principios de transparencia académica y las directrices éticas institucionales en la investigación científica, se declara que para la elaboración de este Trabajo de Fin de Máster se contó con el soporte tecnológico de la herramienta de Inteligencia Artificial Generativa **Gemini (Google)**.

La integración de este modelo se acotó estrictamente como un recurso de asistencia en las siguientes tareas operativas:

1. **Optimización de Código y Análisis de Datos:** Generación de fragmentos de código base en Python y sugerencias de librerías (*pandas*, *scikit-learn*, *matplotlib*) para el proceso de los modelos predictivos.
2. **Soporte de Redacción y Estilo:** Asistencia técnica en la estructuración de determinados apartados, así como en la redacción académica del texto.

En ningún caso el uso de la IA sustituyó los procesos de pensamiento crítico o la autoría intelectual del proyecto. La supervisión metodológica, la selección, adaptación y validación de todas las propuestas algorítmicas, así como la interpretación analítica de los resultados económicos y deportivos de la NBA han sido ejecutadas íntegramente por el autor. El diseño conceptual del Modelo Mínimo Viable (MVP) y las conclusiones derivadas de este estudio se sustentan bajo la responsabilidad analítica exclusiva del autor del trabajo.